


Algoritmos de Bagging:

«El principal objetivo intrínseco de los algoritmos de bagging es el de la reducción de la varianza»

Los métodos de bagging son métodos donde los algoritmos simples son usados en paralelo. El principal objetivo de los métodos en paralelo es el de **aprovecharse de la independencia que hay entre los algoritmos simples**, ya que el error se puede reducir bastante al promediar las salidas de los modelos simples. Es como si, queriendo resolver un problema entre varias personas independientes unas de otras, damos por bueno lo que eligiese la mayoría de las personas.



Métodos paralelos de bagging

Bagging proviene del concepto de **agregación de bootstrap**. Una forma de reducir la varianza de las estimaciones es promediando estimaciones de distintos modelos o algoritmos.


Para obtener la agregación de las salidas de cada modelo simple e independiente, bagging puede usar la votación para los métodos de clasificación y el promedio para los métodos de regresión.

Algoritmos de Boosting:

Por otro lado, dentro de los algoritmos ensamblados tenemos los algoritmos de boosting. Algunos ejemplos de estos algoritmos son el XGBoost o el AdaBoost.

«El principal objetivo de los algoritmos de boosting es el de la reducción del sesgo»

En los algoritmos de boosting, los **modelos simples son utilizados secuencialmente**, es decir, cada modelo simple va delante o detrás de otro modelo simple. El principal objetivo de los métodos secuenciales es el de aprovecharse de la dependencia entre los modelos simples. El rendimiento general puede ser mejorado haciendo que un modelo simple posterior le de **más importancia a los errores cometidos por un modelo simple previo**. Poniendo un ejemplo, es como si nosotros al resolver un problema aprovechásemos nuestro conocimiento de los errores de otros para mejorar en algo intentando no cometerlos nosotros.

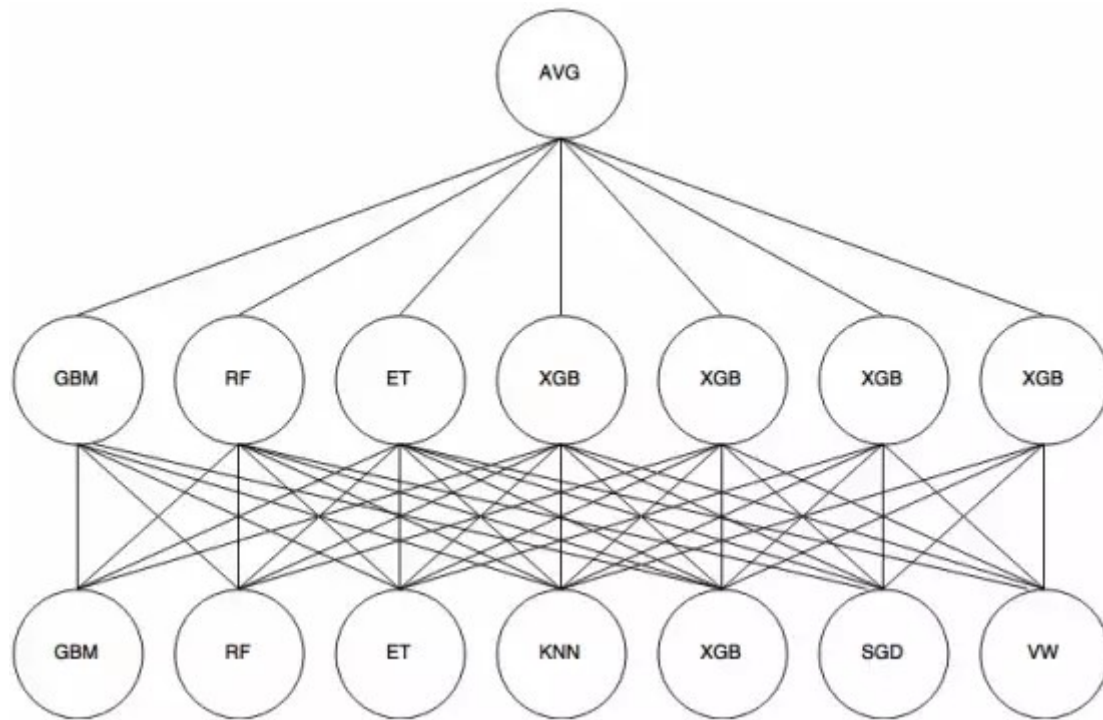


Métodos secuenciales de boosting

Las predicciones de cada modelo simple se combinan por medio de una votación (para problemas de clasificación) o por medio de una suma ponderada (para problemas de regresión) para producir la predicción final. La diferencia con el bagging es que en el boosting los algoritmos no se entrenan independientemente, sino que se ponderan según los errores de los anteriores.

Algoritmos de Stacking:

Stacking is a meta-learning approach in which an ensemble is used to “extract features” that will be used by another layer of ensemble. The following image (from Kaggle Ensembling Guide) shows how this works.



First (Bottom) several different classifiers are trained with the training set, and their outputs (probabilities) are used to train the next layer (middle layer), finally, the outputs (probabilities) of the classifiers in the second layer are combined using the average (AVG). There are several strategies using cross-validation, blending and other approaches to avoid stacking overfitting. But some general rules are to avoid such approach on small datasets and try to use diverse classifiers so that they can “complement” each other. Stacking has been used in several machine learning competitions such as Kaggle and Top Coder. It is definitely a must know in machine learning.

LINK para interpretar AUC:

<https://www.youtube.com/watch?v=4jRBRDbJemM&app=desktop>